

Quant Portfolio-Kaizen

Framework formal de stock picking, benchmark governance, XCDR/XODR, control robusto de downside, validación causal y dashboard cloud costo-cero

Autor: Christopher Jacob Ahumada Robles

En atención a Roberto Carlos Guzmán Orduño

Fecha: Junio 2026

Este documento expone la arquitectura matemática, financiera, estadística y computacional de Quant Portfolio-Kaizen. Incluye definiciones formales, pruebas, objetivos de optimización, construcción del benchmark ξ , conjunto Omega, gobierno de promoción, módulos de la app, arquitectura cloud y riesgos de implementación.

Nota de uso: documento de investigación y arquitectura. No constituye recomendación de inversión personalizada.

Tabla de contenidos resumida

- 1. Resumen ejecutivo y tesis central
- 2. Notación, filtración y espacio de decisión
- 3. Data generating process y sentido físico-estocástico
- 4. Fuentes costo-cero y aproximación point-in-time
- 5. Filtro fundamental sectorial
- 6. Mahalanobis sectorial y anomalías multivariadas
- 7. Régimen macro, curvas de tasas y clasificación hawkish/dovish
- 8. Construcción del benchmark óptimo π
- 9. Alpha bayesiano, Fisher information y CRLB
- 10. Entropía de Shannon y gobierno de concentración
- 11. Covarianza, Ledoit-Wolf y Random Matrix Theory
- 12. Arquitecturas de varianza: EWMA, ARCH, GARCH, EGARCH y Volterra
- 13. PELT y cambios de régimen
- 14. Objetivos clásicos: Sharpe, Sortino, Treynor e Information Ratio
- 15. CVaR, drawdown y downside pathwise
- 16. Optimización robusta y restricciones institucionales
- 17. Black-Litterman bayesiano
- 18. Hierarchical Risk Parity y HERC
- 19. XCDR-v2 y XODR: ratio propietario
- 20. Upside capture, downside capture y dominancia asimétrica
- 21. Downside Preserving Growth Policy
- 22. TailAwareGrowthSleeve y ConvexOpportunityUniverseBuilder
- 23. Optimización de estados y throttle causal
- 24. Reinforcement learning y contextual bandit Kaizen
- 25. Validación nested walk-forward
- 26. White Reality Check, Hansen SPA y PBO
- 27. Promotion gate y StrategyConstitution
- 28. Suitability CFA para usuarios no financieros
- 29. Opciones, volatilidad implícita y límites del snapshot
- 30. Termómetro geopolítico y noticias
- 31. Carry trade y tasas globales
- 32. Backtest, NAV sintético y precios
- 33. Arquitectura de software: core, UI, DB y cloud
- 34. Dashboard y funciones de la app

- 35. Supabase, jobs, artifacts y despliegue costo-cero
- 36. Seguridad, privacidad y firewall de información privada
- 37. UX para usuarios no financieros
- 38. Red-team y failure modes
- 39. Resultados de research y lectura actual
- 40. Teoremas finales de gobernanza cuantitativa
- A. Pseudocódigo del pipeline
- B. Contrato dashboard_payload
- C. Tests mínimos
- D. Checklist de producción
- E. Glosario
- F. Limitaciones costo-cero
- G. Roadmap research
- H. Roadmap UX

1. Resumen ejecutivo y tesis central

Quant Portfolio-Kaizen es un framework de stock picking y asset allocation long-only, costo-cero, diseñado para convertir datos públicos imperfectos en decisiones de portafolio auditables. Su tesis central es que el edge no proviene de maximizar agresivamente una señal, sino de reducir incertidumbre antes de asignar capital. La arquitectura combina filtros fundamentales sectoriales, inferencia de régimen, benchmark governance, control robusto de downside, validación purgada y persistencia cloud por artifacts.

PIT Data -> Signal Reliability -> UncertaintyState -> Robust Control
-> Nested Walk-Forward -> Promotion Gate -> Dashboard Artifact

El sistema no promete dominancia universal sobre todo benchmark. La meta matemáticamente defendible es elegir un benchmark óptimo de mandato, denotado ξ , y buscar active return positivo con menor captura de downside. El conjunto Omega de benchmarks se usa como stress set, no como un único oponente lineal.

$$\begin{aligned} E[R_p - R_{\xi}] &\geq 0, & UC_p &\geq 1, & DC_p &\leq 1, \\ DD_p &\leq DD_{\xi}, & CVaR_p &\leq CVaR_{\xi}, & D_{-}(p) &\leq D_{-}(\xi). \end{aligned}$$

Dictamen metodológico: la app debe comunicar tres estados, no sólo retornos: APPROVED, RESEARCH-ONLY y BLOCKED. Un portafolio puede tener buen retorno y aun así quedar bloqueado si falla suitability, WRC, SPA, PBO o preservación de downside.

2. Notación, filtración y espacio de decisión

El framework no asume que el α sea una constante observable; lo trata como una variable latente estimada bajo una filtración. La implementación debe separar estrictamente lo conocido en la fecha de señal de lo observado después de ejecutar el portafolio. Esta separación es la condición mínima para que una métrica de backtest tenga interpretación económica y no sea sólo una estadística contaminada.

```
U_t = universe as-of approximation
P_{i,t} = adjusted price, V_{i,t} = volume
r_{i,t} = P_{i,t}/P_{i,t-1} - 1
F_t = sigma(P_{i,s}, V_{i,s}, M_s, FUND_{i,tau}, O_{i,s}^{\{snap\}}, N_s : s \leq t, \tau \leq t)
```

La política de portafolio es una función medible respecto a la filtración. En términos de ingeniería financiera, esto significa que cada feature usada por el optimizador debe tener una fecha de disponibilidad menor o igual a la fecha de señal.

```
pi_t : F_t -> Delta_N,
Delta_N = { w in R^N : w_i \geq 0, 1'w = 1 },
R_{p,t+1} = w_t' r_{t+1} - TC_t.
```

Proposición 2.1 (Causalidad de la política). Si todos los inputs de π_t son F_t -medibles, entonces w_t es F_t -medible y el retorno OOS $R_{p,t+1}$ no contamina la decisión.

Demostración. Por definición, una composición finita de funciones medibles es medible. Si cada feature pertenece a F_t y el solver es determinístico dado el estado, entonces $w_t = \pi_t(F_t)$ pertenece a F_t . Como r_{t+1} no pertenece a F_t , sólo afecta la evaluación posterior, no la selección. QED.

3. Data generating process y sentido físico-estocástico

El proceso de precios se representa como semimartingala con difusión, volatilidad condicional y jumps. La app no estima un modelo estructural completo de equilibrio general; usa esta formulación como mapa conceptual para ubicar drift, varianza, discontinuidades y régimen.

$$dS_{\{i,t\}}/S_{\{i,t\}} = \mu_{\{i,t\}} dt + \sigma_{\{i,t\}} dW_{\{i,t\}} + J_{\{i,t\}} dN_{\{i,t\}}, \\ z_t \text{ in } \{\text{risk-on, inflation shock, credit stress, liquidity crisis, recovery}\}.$$

La presencia de variación cuadrática finita justifica modelar varianza realizada y volatilidad condicional. Los jumps y cambios de régimen justifican PELT, EVT y penalizaciones por cola. El drift μ_t es de baja señal-ruido; por eso se aplica shrinkage bayesiano y CRLB.

$$[\log S]_t = \int_0^t \sigma_s^2 ds + \sum_{0 \leq s \leq t} (\Delta \log S_s)^2.$$

Lema 3.1 (Separación drift-volatilidad). En horizontes cortos, el error de estimación de μ domina al error de estimación de σ bajo baja SNR.

Demostración. Si $r_t \sim N(\mu, \sigma^2)$, $\text{Var}(\mu_{\text{hat}}) = \sigma^2/T$. Para acciones diarias, $|\mu|$ es pequeño frente a σ . Por tanto, el ratio $|\mu_{\text{hat}}|/\sqrt{\text{Var}(\mu_{\text{hat}})}$ crece lentamente con T . La varianza condicional, aunque ruidosa, exhibe clustering y puede estimarse con más estabilidad relativa. QED.

4. Fuentes costo-cero y aproximación point-in-time

La restricción costo-cero obliga a usar yfinance, SEC EDGAR, FRED, Banxico, ECB, BCB, BoC, ForexFactory/FairEconomy, GDELT, Google News RSS y snapshots de opciones de Yahoo. Ninguna de estas fuentes equivale a Bloomberg/FactSet PIT institucional.

Fuente	Uso	Riesgo	Mitigación
yfinance	Precios, volumen, fundamenta	Options timestamps y no PIT est	Catche, validación de nulos, PIT confidence
SEC EDGAR	Companyfacts, filing dates, accepted timestamps	Capturas estapaja por taxonom	Availability_Date y accounting lag
FRED/Banxico/ECB/BCB/BoC	IBRs, tasas, macro	Frecuencia heterogénea	Sampling discreto por fecha de observación
GDELT/RSS	Atención geopolítica	Query bias y comparabilidad cruz	Zarobusto within-topic y fallback cualitativo
Yahoo options	IV ATM, skew, bid/ask, OI	Sin histórico causal de opciones	Snapshot sólo diagnóstico contemporáneo

$$\text{PITConfidence}_i = \text{SourceConfidence}_i * \exp(-\text{StalenessDays}_i/540) * \text{Coverage}_i.$$

Todo ratio derivado de Yahoo debe etiquetarse como PIT approximation. SEC EDGAR mejora causalidad porque la fecha de filing y accepted timestamp permiten bloquear datos que aún no estaban disponibles.

5. Filtro fundamental sectorial

La regla central es no comparar peras con manzanas: un P/E de software no tiene la misma distribución que un P/E de utilities. Por tanto, cada ratio se normaliza dentro de sector y, cuando la cobertura es baja, se aplica winsorization y score de confianza.

Ratio	Definición	Interpretación
ROIC	NOPAT / Invested Capital	Calidad de asignación de capital.
EV/EBITDA	(MarketCap + Debt - Cash)/EBITDA	Valoración neutral a estructura de capital.
FCF Yield	FreeCashFlow / MarketCap	Caja real por unidad de valor de mercado.
Net Debt / EBITDA	(Debt - Cash)/EBITDA	Apalancamiento operativo-crediticio.
Piotroski F-Score	$\sum_{k=1}^9 1_{\{\text{criterion}_k\}}$	Salud financiera discreta.
Asset Turnover	Revenue / AvgAssets	Eficiencia operativa.
Altman Z	$1.2X1+1.4X2+3.3X3+0.6X4+1.0X5$	Distress probability proxy.
Interest Coverage	EBIT / InterestExpense	Resiliencia a tasas altas.
Retention Ratio	$1 - \text{Dividends}/\text{NetIncome}$	Motor endógeno de crecimiento.
Earnings Yield	E/P	Comparación contra tasa libre de riesgo.
P/B	Price / BookValuePerShare	Value sectorial.
ROE	NetIncome / Equity	Rentabilidad patrimonial con riesgo de leverage bias.

$$Z_{\{i,k\}^{\{\text{sector}\}}} = \frac{(x_{\{i,k\}} - \text{median}_{\{j:g(j)=g(i)\}} x_{\{j,k\}})}{(1.4826 * \text{median}_j |x_{\{j,k\}} - \text{median}(x_{\{g,k\}})| + \text{eps})}.$$

Proposición 5.1 (Validez del z-score robusto sectorial). Si la distribución del ratio dentro de sector es unimodal con contaminación acotada, el z-score basado en mediana y MAD tiene breakdown point superior al z-score clásico.

Demostración. La media y desviación estándar tienen breakdown point cero: un outlier arbitrario puede desplazar ambos estimadores. La mediana y MAD toleran hasta 50% de contaminación antes de divergir. El factor 1.4826 calibra el MAD a sigma bajo normalidad. QED.

6. Mahalanobis sectorial y anomalías multivariadas

El vector fundamental de una empresa no debe evaluarse ratio por ratio de forma independiente. La distancia de Mahalanobis mide qué tan lejos está una compañía del centroide robusto de su sector considerando correlaciones entre ratios.

$$\begin{aligned}x_i &= (Z_{\{i,1\}}, \dots, Z_{\{i,K\}})', \\ D_M(i)^2 &= (x_i - m_g)' S_g^{-1} (x_i - m_g).\end{aligned}$$

Una distancia alta puede ser oportunidad o value trap. La decisión depende del signo del alpha posterior, cobertura fundamental, liquidez y riesgo textual SEC.

Proposición 6.1 (Invariancia afín de Mahalanobis). Para una transformación no singular $y = Ax + b$, la distancia de Mahalanobis es invariante si la covarianza se transforma como AS_gA' .

Demostración. Sustituyendo $y_{i-m} = A(x_{i-m} - m_x)$ y $S_y^{-1} = (A')^{-1} S_x^{-1} A^{-1}$, se obtiene $(y_{i-m})' S_y^{-1} (y_{i-m}) = (x_{i-m} - m_x)' S_x^{-1} (x_{i-m} - m_x)$. QED.

7. Régimen macro, curvas de tasas y clasificación hawkish/dovish

El régimen se estima usando curvas soberanas, inflación, crédito, liquidez, momentum de benchmark, pendiente 10Y-2Y y variables alternativas. Las tasas son procesos discretos de observación, no trayectorias continuas: la visualización debe respetar fechas reales y frecuencias heterogéneas.

```
CurveSlope_t = y_{10Y,t} - y_{2Y,t},
PolicyImpulse_t = Delta PolicyRate_t + Delta Inflation_t,
CreditStress_t = z(BAA_t - AAA_t).
```

La etiqueta hawkish/dovish se deriva de presión de política monetaria; bullish/bearish de price action, amplitud, volatilidad y crédito. La clasificación no debe confundirse con predicción perfecta de retornos.

Estado	Condición típica	Efecto esperado
Dovish Bull	curva relajando + momentum positivo	growth y duración reciben soporte
Hawkish Bull	momentum positivo + tasas altas	quality/cash-flow domina speculative growth
Dovish Bear	relajación por estrés	riesgo de recesión; defensive sleeve sube
Hawkish Bear	tasas restrictivas + drawdown	reducir beta, CVaR y concentración

8. Construcción del benchmark óptimo ξ

El benchmark ξ no se elige por conveniencia. Se estima como el benchmark que mejor representa el mandato del portafolio. Omega es el conjunto de candidatos: SPY, QQQ, ACWI, VT, VTI, IWM, USMV, SPLV, MTUM, QUAL, VLUE y ETFs sectoriales.

```
Omega = {omega_1,...,omega_K},  
 $\xi^* = \operatorname{argmax}_{\{\xi \text{ in } \Omega\}} \operatorname{Fit}(p,\xi).$   
  
 $\operatorname{Fit}(p,\xi) = a_1 \operatorname{Corr}(R_p,R_\xi) - a_2 |\operatorname{Beta}_{\{p,\xi\}}-1|$   
          -  $a_3 \operatorname{TrackingError}(p,\xi) + a_4 \operatorname{SectorOverlap}(p,\xi)$   
          +  $a_5 \operatorname{FactorOverlap}(p,\xi) + a_6 \operatorname{MandateMatch}(p,\xi).$ 
```

Para un mandato absoluto defensivo, ξ puede ser USMV/SPLV; para tecnología growth puede ser QQQ/XLK; para global puede ser ACWI/VT. Comparar todo contra QQQ sin mandato growth tecnológico es benchmark mismatch.

Proposición 8.1 (Gobernanza de benchmark). El Information Ratio y Treynor son métricas interpretables sólo si ξ representa el riesgo sistemático del mandato.

Demostración. IR divide active return por tracking error respecto a ξ . Si ξ no comparte universo, país, sector o factor dominante, el tracking error mide desalineación estructural, no skill. Treynor usa beta contra ξ ; un beta mal definido invalida la razón. QED.

9. Alpha bayesiano, Fisher information y CRLB

El alpha score se modela como estimador con incertidumbre. No basta ordenar activos por Composite_Score; debe penalizarse el error estándar posterior, la baja cobertura fundamental y el bajo tamaño muestral efectivo.

```
alpha_i | F_t ~ N(alpha_hat_i, tau_i^2),  
I(mu_i) = T_i / sigma_i^2,  
CRLB(mu_hat_i) >= sigma_i^2 / T_i.
```

```
mu_i^{robust} = alpha_hat_i * |alpha_hat_i| / (|alpha_hat_i| + sqrt(CRLB_i) + eps).
```

Proposición 9.1 (Shrinkage por CRLB). Si CRLB aumenta manteniendo α_{hat} fijo, el alpha robusto disminuye monótonamente en magnitud.

Demostración. Sea $f(c) = a|a|/(|a| + \sqrt{c})$. Para $c > 0$, df/dc tiene signo opuesto a a y magnitud positiva en el denominador, por tanto $|f(c)|$ decrece. QED.

La información de Fisher es el puente entre estadística y física: cuantifica curvatura local de la log-verosimilitud. Baja curvatura implica parámetros poco identificables y, por tanto, menor capital asignable.

10. Entropía de Shannon y gobierno de concentración

La entropía controla tanto la concentración de pesos como la discriminación del ranking. Una señal con softmax plano tiene alta incertidumbre transversal; una cartera con un solo peso dominante tiene fragilidad idiosincrática.

$$\begin{aligned} H(w) &= - \sum_i w_i \log(w_i), \\ H_N(w) &= H(w) / \log(N), \\ p_i &= \exp(s_i/\tau) / \sum_j \exp(s_j/\tau). \end{aligned}$$

El sistema usa entropía como governor, no como fin absoluto: se evita concentración espuria, pero no se obliga a igual ponderación si existe evidencia causal y robusta.

Lema 10.1 (Cotas de entropía normalizada). Para w en Δ_N , $H_N(w)$ pertenece a $[0,1]$.

Demostración. Por concavidad de $-x \log x$, la entropía mínima ocurre en vértice del simplex y vale 0; la máxima ocurre en $w_i=1/N$ y vale $\log N$. Dividir por $\log N$ da la cota. QED.

11. Covarianza, Ledoit-Wolf y Random Matrix Theory

La matriz de covarianza muestral es inestable cuando N/T no es despreciable. El framework usa shrinkage y limpieza espectral inspirada en Marchenko-Pastur para separar modos informativos de ruido.

```
lambda_pm = sigma^2 (1 +- sqrt(q))^2,    q=N/T.  
Sigma_RMT = V diag(lambda_clean) V',  
lambda_clean_j = lambda_j if lambda_j > lambda_+ else mean(lambda_noise).
```

Proposición 11.1 (PSD de limpieza espectral). Si todos los eigenvalores limpiados son no negativos, Σ_{RMT} es semidefinida positiva.

Demostración. Para cualquier x , $x'V \text{diag}(\lambda_{\text{clean}})V'x = y'\text{diag}(\lambda_{\text{clean}})y = \sum_j \lambda_j^{\text{clean}} y_j^2 \geq 0$.
QED.

El RMT crowding penalty se interpreta físicamente: cuando pocos modos explican demasiada varianza, el mercado está crowded y la diversificación aparente puede colapsar.

$\text{EffectiveRank}(\Sigma) = \exp(-\sum_j p_j \log p_j)$, $p_j = \lambda_j / \sum_k \lambda_k$.

12. Arquitecturas de varianza: EWMA, ARCH, GARCH, EGARCH y Volterra

La app selecciona arquitectura de varianza por AIC, BIC y log-likelihood, pero la promoción exige mejora OOS en QLIKE. AIC/BIC in-sample no bastan.

EWMA: $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1-\lambda) \epsilon_{t-1}^2$
GARCH: $h_t = \omega + \alpha \epsilon_{t-1}^2 + \beta h_{t-1}$
EGARCH: $\log h_t = \omega + \beta \log h_{t-1} + \alpha(|z_{t-1}| - E|z|) + \gamma z_{t-1}$

AIC = $2k - 2 \log L$, BIC = $k \log T - 2 \log L$,
QLIKE(h, r) = $r_t^2/h_t + \log h_t$.

El fractional Volterra kernel es una extensión research-only para memoria rough en volatilidad. Debe ser causal: $K(t,s)=0$ para $s>t$.

$\sigma_t^2 = \sigma_0^2 + \int_0^t K_H(t-s) b(\sigma_s) ds$
 $\quad + \int_0^t K_H(t-s) \nu(\sigma_s) dW_s,$
 $K_H(u) = u^{H-1/2}/\Gamma(H+1/2), u \geq 0.$

13. PELT y cambios de régimen

PELT detecta cambios estructurales en retornos, volatilidad realizada, drawdown y tracking error. Su uso correcto es diagnóstico y throttle de estado, no excusa para ajustar retrospectivamente el portafolio.

$$\min_{m, \tau_1, \dots, \tau_m} \sum_{j=0}^m C(y_{\tau_j+1:\tau_{j+1}}) + \beta m.$$

El costo C puede ser negativo log-likelihood gaussiana por segmento, o suma de cuadrados centrada. La penalización β evita sobresegmentación.

Proposición 13.1 (Causalidad operativa de PELT). Si PELT se recalibra únicamente con datos hasta t , el régimen z_t es $\mathcal{F}_t$ -medible.

Demostración. El algoritmo puede usar todo el historial hasta t , pero no fechas posteriores. La segmentación final hasta t es función determinística de $y_{\leq t}$; por tanto pertenece a $\mathcal{F}_t$. QED.

14. Objetivos clásicos: Sharpe, Sortino, Treynor e Information Ratio

La app permite varios objetivos, pero cada uno tiene dominio de validez. Sortino penaliza downside; Sharpe penaliza varianza total; Treynor requiere beta confiable; Information Ratio requiere benchmark coherente.

```
Sharpe = E[R_p-r_f] / sigma_p,  
Sortino = E[R_p-r_f] / sqrt(E[min(R_p-r_f,0)^2]),  
Treynor = E[R_p-r_f] / beta_{p,xi},  
IR = E[R_p-R_xi] / sigma(R_p-R_xi).
```

Lema 14.1 (Inestabilidad del Sortino puro). Si el número de observaciones negativas es pequeño, el estimador de downside deviation tiene alta varianza.

Demostración. El estimador depende sólo de la submuestra negativa. Cuando esa submuestra es escasa, pequeñas perturbaciones cambian mucho la raíz de la media de cuadrados negativos. Por eso se requiere shrinkage, CVaR y nested validation. QED.

15. CVaR, drawdown y downside pathwise

El framework prioriza riesgo de cola y pérdida pathwise sobre volatilidad total. Para usuarios no financieros, drawdown y CVaR son más interpretables que varianza.

$$\text{VaR}_\alpha(L) = \inf\{x : P(L \leq x) \geq \alpha\},$$

$$\text{CVaR}_\alpha(L) = E[L \mid L \geq \text{VaR}_\alpha(L)].$$

$$\text{NAV}_t = \text{NAV}_{t-1}(1 + w_{\tau(t)}r_t - \text{TC}_t),$$

$$\text{DD}_t = \text{NAV}_t / \max_{s \leq t} \text{NAV}_s - 1.$$

Proposición 15.1 (Convexidad de CVaR empírico). La formulación de Rockafellar-Uryasev de CVaR empírico es convexa en w para pérdidas lineales.

Demostración. $\text{CVaR}_\alpha(L_w) = \min_z z + c \sum_t (L_{w,t} - z)^+$. $L_{w,t}$ es lineal en w y la función parte positiva es convexa; suma y minimización parcial preservan convexidad. QED.

16. Optimización robusta y restricciones institucionales

El problema productivo no es maximizar retorno esperado crudo. Es construir pesos en el simplex bajo límites de concentración, sector, liquidez, factor beta, ADV, CVaR y suitability.

```
max_{w in Delta_N} U(w;mu,Sigma) - lambda_TC TC(w) - lambda_H(1-H_N(w))
s.t. w_i <= w_max, sector_g(w)<=cap_g, CVaR(w)<=c, DD(w)<=d,
    |beta_factor(w)| <= beta_cap, |Q_i|/ADV_i <= theta.
```

```
Robust: max_w min_{mu in U_mu, Sigma in U_Sigma} U(w;mu,Sigma),
U_mu = {mu : (mu-mu_hat)'Omega^{-1}(mu-mu_hat) <= epsilon}.
```

La solución SLSQP/multistart es aceptable para prototipo, pero todo resultado debe pasar validación OOS. HRP/HERC se usan cuando mu es demasiado incierta.

17. Black-Litterman bayesiano

Black-Litterman estabiliza alpha combinando un prior de equilibrio con views del motor bayesiano. Es especialmente útil cuando el alpha cross-sectional tiene baja información.

$$\mu_{BL} = [(\tau \Sigma)^{-1} + P' \Omega^{-1} P]^{-1} [(\tau \Sigma)^{-1} \pi + P' \Omega^{-1} q].$$

π representa retornos implícitos de equilibrio; q viene de Bayesian_Alpha_Mean; Ω se escala con Bayesian_Alpha_Std, CRLB y cobertura fundamental. P puede representar views absolutas por activo o relativas sectoriales.

Proposición 17.1 (BL como precisión ponderada). El posterior BL pondera prior y views por sus matrices de precisión.

Demostración. La fórmula es la media posterior normal-normal multivariada. Los términos $(\tau \Sigma)^{-1}$ y $P' \Omega^{-1} P$ son precisiones. Mayor incertidumbre reduce peso informacional. QED.

18. Hierarchical Risk Parity y HERC

HRP evita inversión directa de una covarianza inestable. Construye clusters por correlación, ordena activos por árbol jerárquico y asigna riesgo recursivamente.

```
d_{ij} = sqrt((1-rho_{ij})/2),  
cluster tree -&gt; quasi diagonalization -&gt; recursive bisection.
```

HRP no garantiza alpha superior, pero es una defensa robusta cuando el vector μ no es confiable. En el framework se usa como candidato alternativo y benchmark interno de construcción.

19. XCDR-v2 y XODR: ratio propietario

XCDR/XODR busca capturar upside relativo sin relajar downside. El objetivo no es superar el retorno máximo de Omega en todo período, sino dominar al benchmark xi y permanecer robusto contra Omega.

$$\begin{aligned} \text{XCDR}(w) = & [w' \mu_{\text{robust}} - \mu_{\text{xi}}] / \\ & \sqrt{D_{-}^2(w) + \lambda_C \text{CVaR}^2(w) + \lambda_D \text{DD}^2(w) + \lambda_R w' \Sigma_{\text{RMT}} w + \lambda_U w' U w} \\ & - \lambda_T \text{TO}(w) + \lambda_H H_N(w). \end{aligned}$$

Omega robust boundary:

$$\begin{aligned} D_{\text{Omega}}^{\text{robust}} &= Q_q(\{D(\omega) : \omega \in \text{Omega}\}), \\ U_{\text{Omega}}^{\text{robust}} &= Q_{\tau}(\{U(\omega) : \omega \in \text{Omega}\}). \end{aligned}$$

$$\begin{aligned} \text{Penalty}_{\text{Omega}}(w) = & \lambda_1 [D_{-}(w) - D_{\text{Omega}}]_{+}^2 + \lambda_2 [\text{CVaR}(w) - \text{CVaR}_{\text{Omega}}]_{+}^2 \\ & + \lambda_3 [\text{DD}(w) - \text{DD}_{\text{Omega}}]_{+}^2. \end{aligned}$$

20. Upside capture, downside capture y dominancia asimétrica

El par UC/DC mide convexidad empírica respecto al benchmark. UC mayor a uno y DC menor a uno expresa mejor participación en días positivos que en días negativos.

$$\begin{aligned} UC_p &= E[R_p \mid R_{xi} > 0] / E[R_{xi} \mid R_{xi} > 0], \\ DC_p &= E[R_p \mid R_{xi} < 0] / E[R_{xi} \mid R_{xi} < 0]. \end{aligned}$$

Como el denominador de DC es negativo, la implementación debe cuidar signos. En reporting se usa convención de captura de pérdida positiva cuando el benchmark cae.

Proposición 20.1 (UC/DC no implica dominancia estocástica). $UC > 1$ y $DC < 1$ no garantizan dominancia estocástica de primer orden.

Demostración. Las condiciones son momentos condicionales sobre dos particiones del benchmark. No ordenan toda la función de distribución acumulada ni controlan colas extremas fuera del promedio condicional. Por eso se agregan CVaR, DD y WRC/SPA. QED.

21. Downside Preserving Growth Policy

DPG separa varianza positiva de downside. La idea es permitir growth si el retorno esperado OOS mejora y si DD, CVaR y downside no se deterioran frente al baseline defensivo.

$$w_t = \alpha_t w_{\text{capital},t} + \beta_t w_{\text{growth},t} + \gamma_t w_{\text{alpha},t},$$
$$\alpha_t + \beta_t + \gamma_t = 1.$$
$$\max_w [E(R_p - R_{xi})] / [D_-(w) + \lambda_C \text{CVaR}(w) + \lambda_D \text{DD}(w) + \lambda_U U(w)]$$
$$+ \lambda_+ \sigma_+(w).$$

La política cae a capital preservation si ICIR $\leq$ 0, si downside capture $\geq$ 1, o si validation detecta breach de CVaR/DD superior al umbral pre-registrado.

22. TailAwareGrowthSleeve y ConvexOpportunityUniverseBuilder

El research mostró que el overlay protege downside, pero el alpha faltante está antes: en el universo de oportunidades y el growth sleeve. Por eso se introduce un builder que filtra activos con mayor convexidad upside real.

$$S_i = a1 M_i + a2 \alpha_i + a3 Q_i + a4(\beta_i^{+} - \beta_i^{-}) - a5 \text{TailBeta}_i - a6 \text{MCVaR}_i - a7 \text{DDDepth}_i - a8 \text{Crowding}_i.$$

$$\beta_i^{+} = E[r_i \mid r_{xi} > 0] / E[r_{xi} \mid r_{xi} > 0],$$

$$\beta_i^{-} = E[r_i \mid r_{xi} < 0] / E[r_{xi} \mid r_{xi} < 0],$$

$$\text{TailBeta}_i = E[r_i \mid r_{xi} \leq q_{\alpha}(r_{xi})] / E[r_{xi} \mid r_{xi} \leq q_{\alpha}(r_{xi})].$$

Señales permitidas: residual momentum vs xi, momentum sectorial, quality/growth sectorial, ROIC, FCF yield, revenue growth, liquidez, tail beta cap, downside beta y RMT crowding penalty.

23. Optimización de estados y throttle causal

El state optimizer decide exposición a growth/alpha según régimen, volatilidad, crowding, drawdown stress, entropía y breaches de validation. No selecciona activos usando test.

```
s_t = [trend, volRank, drawdownStress, RMTcrowding, dispersion,  
       downsideCaptureValidation, CVaRBreachValidation, PELTregime,  
       GARCHvol, entropy, CRLB].  
  
(beta_t,gamma_t) = f(s_t),  
stress -&gt; beta,gamma down; expansion -&gt; beta up; recovery -&gt; beta moderate.
```

La lógica de control robusto se parece a un controlador con saturación: evita que una señal fuerte rompa budgets de downside.

24. Reinforcement learning y contextual bandit Kaizen

RL directo para elegir tickers o pesos es estadísticamente peligroso con pocas trayectorias, baja SNR y no estacionariedad. La forma viable es contextual bandit para hiperparámetros y objetivos, sujeto a gates.

```
s_t = [z_t, IC_t, PBO_t, DD_t, CVaR_t, Turnover_t, profile_t],  
a_t = [objective, lambda_Sigma, lambda_CVaR, w_max, sectorCap, targetVol].  
  
r_{t+1} = R_{p,t+1} - l1 CVaR_{t+1} - l2 DD_{t+1}  
        - l3 Turnover_{t+1} - l4 Cost_{t+1} - l5 1_{SuitabilityBreach}.
```

LinUCB o Thompson Sampling son suficientes como primera capa. Offline RL completo queda research-only hasta tener muchos episodios reales y policy evaluation robusta.

25. Validación nested walk-forward

La validación correcta separa train, validation, test y final holdout. La selección de hiperparámetros ocurre en validation; el test queda intocable.

```
Train(t) -&gt; Validation(t) -&gt; Test(t,t+h) -&gt; FinalHoldout.  
D_train(t) subset F_t,  
D_test(t,t+h) intersection D_train/validation(t) = empty.
```

Purging elimina overlap de labels; embargo desplaza la fecha de ejecución para evitar contaminación por microestructura, reporting lag o ventanas solapadas.

Proposición 25.1 (Test intocable). Si θ se selecciona sólo con train/validation y se evalúa una vez en test, el estimador OOS no está contaminado por selección directa en test.

Demostración. La política final $\theta^* = A(D_{\text{train}}, D_{\text{val}})$ es medible respecto a F_t . D_{test} no entra a $\mathcal{A}$. La evaluación en D_{test} es posterior y no retroalimenta θ dentro de la misma partición. QED.

26. White Reality Check, Hansen SPA y PBO

Cuando se prueban muchos candidatos, el máximo performance observado está sesgado al alza. WRC y SPA testean si el mejor candidato supera un benchmark después de ajustar por data snooping.

$$d_{\{k,t\}} = R_{\{k,t\}} - R_{\{\text{bench},t\}},$$
$$T_n = \max_k \sqrt{n} \text{ mean}(d_k),$$
$$\text{WRC}_p = P^*(T_n^* \geq T_n).$$
$$\text{PBO} = P(\lambda \leq 0),$$
$$\lambda = \text{logit}(\text{rank_00S}(\text{selected_IS})).$$

El framework usa bootstrap por bloques para respetar dependencia serial. La promoción productiva exige $\text{WRC} < 0.05$, $\text{SPA} < 0.05$ y $\text{PBO} < 0.10$ en familia congelada.

27. Promotion gate y StrategyConstitution

StrategyConstitution congela features permitidos, hiperparámetros, benchmark set, complexity budget y gates. Es una defensa contra flexibilidad excesiva del framework.

```
PromotionGate = { DXCDR>0, PBO<0.10, WRC_p<0.05, SPA_p<0.05,
                  ICIR>0, QLIKE_new<QLIKE_base, DD<DDmax, CVaR<CVaRmax }.
```

Si una estrategia sólo funciona con un punto hiperparamétrico estrecho, se clasifica como research-only. Si falla PBO/WRC/SPA, no se promueve aunque tenga retorno alto.

Estado	Condición	UI
Promoted	Pasa suitability y promotion gate	Recommended allocation
Research-only	Buen research pero falla gate estricto	Evidence, no recommendation
Blocked	Rompe suitability/risk hard limits	Allocation blocked

28. Suitability CFA para usuarios no financieros

La app está diseñada para usuarios no financieros. Por tanto, antes del optimizador debe existir un suitability engine que convierta horizonte, capital, liquidez y tolerancia a drawdown en restricciones duras.

```
Vol_p <= Vol_max(profile),  
CVaR_p <= CVaR_max(profile),  
DD_p <= DD_max(profile),  
N <= N_capital, w_i <= w_max(profile).
```

El producto no debe mostrar 'recomendado' si el portafolio está fuera de perfil, aunque el backtest sea atractivo. Esta es una regla CFA de suitability y comunicación de riesgo.

29. Opciones, volatilidad implícita y límites del snapshot

Yahoo ofrece snapshots de opciones: bid, ask, implied volatility, open interest, strikes y expiraciones. Esto permite diagnóstico contemporáneo, pero no backtest causal de opciones históricas.

```
IV_ATM = IV(K approximately S, DTE),  
Skew = IV_put_OTM - IV_call_OTM,  
PutCallOI = OI_put / OI_call.
```

La superficie de volatilidad del portafolio se agrega por pesos, moneyness y DTE. Debe comunicarse como snapshot, no como serie histórica validada.

30. Termómetro geopolítico y noticias

El termómetro geopolítico mide atención anormal, no probabilidad objetiva de conflicto. Su estadística correcta es within-topic robust z-score, no comparación cruda entre queries.

$$Z_{\{k,t\}}^{\text{robust}} = (V_{\{k,t\}} - \text{median}(V_{\{k,\tau\}})) / (1.4826 \text{ median_tau } |V_{\{k,\tau\}} - \text{median}(V_{\{k,\tau\}})| + \text{eps}).$$

Los nulos aparecen cuando no hay suficiente historia/dispersión para estimar un z-score robusto. En ese caso, la tabla debe mostrar fallback cualitativo y no usar el dato como overlay de riesgo.

El mapa mundial de noticias requiere geocodificación robusta. Regex por país ayuda, pero GDELT/RSS puede mencionar países no centrales al evento. La app debe etiquetar esto como attention map.

31. Carry trade y tasas globales

La tabla de carry trade compara diferenciales de tasas, volatilidad FX proxy y riesgo de evento. Sin datos de forwards, basis y hedging costs, es research diagnostic, no recomendación ejecutable.

$$\text{CarryScore}_{\{a,b\}} = (r_a - r_b) / (\sigma_{\text{FX}} + \lambda_{\text{event}} \text{EventRisk} + \lambda_{\text{drawdown}} \text{DD}_{\text{FX}}).$$

SOFR, SONIA, ESTR y TONAR sustituyen referencias tipo LIBOR. La curva debe respetar frecuencias discretas por país y no interpolar visualmente como si todo fuera continuo.

32. Backtest, NAV sintético y precios

El portafolio no tiene precio observado como un ETF. Por eso se reconstruye un NAV sintético a partir de holdings OOS y precios diarios observados. Debe etiquetarse como portfolio price path o synthetic NAV.

$$\begin{aligned} \text{NAV}_t &= \text{NAV}_{\{t-1\}}(1 + \sum_i w_{\{i, \tau(t)\}} r_{\{i, t\}} - \text{TC}_t), \\ \text{BenchmarkPrice}_t &= \text{observed adjusted price of xi.} \end{aligned}$$

El drawdown se calcula siempre desde NAV diario, no desde puntos de rebalance aislados. Esto evita la gráfica plana incorrecta.

33. Arquitectura de software: core, UI, DB y cloud

La regla de ingeniería es Core = source of truth, UI = renderer, DB = audit layer. El frontend no debe recomputar métricas financieras.

DataLayer > FeatureLayer > SignalLayer > PortfolioLayer > BacktestLayer > RiskLayer > UILayer

Módulo	Función
quant_stockpicker_core.py	Motor principal: datos, señales, optimización, backtest, risk diagnostics
run_xcdr_v3_parallel_research.py	Research paralelo XCDR/XODR, WRC/SPA/PBO, weights artifact
stockpicker_app.py	Renderer Streamlit, dashboard, tabs, user controls
supabase_store.py	Persistencia de runs y artifacts
cloud_daily_refresh.py	Precompute diario antes de mercado
quant_core/promotion_gate.py	Contratos de promoción productiva

34. Dashboard y funciones de la app

La app expone módulos: Dashboard/Overview, Allocation, Research Strategy, Price Path, Risk, Validation, Market Regime, Options, Fundamentals, Data Freshness y Advanced. Para producción móvil se recomienda agrupar en Dashboard, Portfolio, Risk, Market, Evidence, Assistant y Advanced.

Vista	Contenido	Usuario objetivo
Overview	Estado, suitability, promotion, macro	Todos
Allocation	Pesos, sectores, razones de inclusión	Todos
Research Strategy	XCDR/XODR vs xi, WRC/SPA/PBO, pesos research	Analyst
Risk	Volatilidad, CVaR, drawdown, PELT, GARCH	Analyst/Expert
Validation	Promotion tests, CPCV/PBO, SPA	Expert
Market	Tasas, régimen, noticias, carry diagnostic	Todos con microcopy
Advanced	Raw artifacts y debugging	Admin

La precarga diaria escribe dashboard_payload en Supabase. Al abrir, la app intenta cargar ese artifact; sólo recalcula si el usuario presiona Run Allocation Engine.

35. Supabase, jobs, artifacts y despliegue costo-cero

La arquitectura cloud recomendada es render-first: GitHub Actions actualiza a las 08:40 CT, Supabase guarda artifacts y la UI online sólo consulta.

```
GitHub Actions -> cloud_daily_refresh.py -> run_pipeline(config)
-> Supabase runs + run_artifacts.dashboard_payload -> Streamlit/Next.js renderer.
```

Tabla	Uso
runs	Auditoría de configuración, benchmark, estado y versión
run_artifacts	dashboard_payload, backtest_path_bundle, gates, freshness
portfolio_weights	Pesos por run
backtest_perf	Performance walk-forward
risk_diagnostics	Métricas de riesgo
jobs	Cola de optimización futura

Para 10 usuarios, el dato de mercado debe ser global y compartido; portafolios, perfiles, runs y chats deben estar aislados por user_id y RLS.

36. Seguridad, privacidad y firewall de información privada

La `service_role` de Supabase nunca debe estar en frontend. Debe vivir sólo en jobs confiables o server-side. El `side/private` portfolio no debe alimentar scoring público, RAG ni recomendaciones para terceros.

```
PublicResearchData intersection PrivateMNPI = empty,  
RAGContext_user_a intersection Portfolio_user_b = empty.
```

La app implementa auth local con `bcrypt/JWT` cookie y roles `admin/analyst/viewer`. En cloud multiusuario, Supabase Auth + RLS debe ser frontera oficial.

37. UX para usuarios no financieros

El rigor matemático no debe obligar al usuario a interpretar tablas crudas. El primer pantallazo debe mostrar estado, retorno, downside, benchmark y acción recomendada. WRC/SPA/PBO pertenecen a Evidence o Expert Mode.

Término técnico	Texto usuario
Promotion gate	Strategy confidence
CVaR	Tail loss risk
Drawdown	Peak-to-trough loss
Synthetic NAV	Portfolio price path
Research-only	Needs more evidence

El chatbot debe explicar, guiar y tutorializar; no debe inventar recomendaciones ni saltarse suitability/promotion gates.

38. Red-team y failure modes

La estrategia debe intentarse destruir antes de promocionarse: cambiar ventanas, universo, benchmark set, costos, seed, bootstrap, crisis windows, excluir sectores ganadores y eliminar top winners.

- Si el retorno desaparece al eliminar top winners, el alpha puede ser concentración retrospectiva.
- Si WRC/SPA falla, el máximo observado puede ser data snooping.
- Si PBO es alto, la selección de hiperparámetros no es estable.
- Si CVaR sube aunque DD baje, la cola diaria sigue vulnerable.
- Si ξ cambia drásticamente por ventana, el mandato no está bien identificado.

Research-only if: $WRC_p \geq 0.05$ or $SPA_p \geq 0.05$ or $PBO \geq 0.10$
or $UC \leq 1$ or $DC \geq 1$ or $CVaR_p \geq CVaR_{\xi}$ or $DD_p \geq DD_{\xi}$.

39. Resultados de research y lectura actual

El research reciente identificó candidatos con active return positivo, pero también mostró una frontera real entre mayor retorno y control de cola. enhanced_growth_anchor_dd_budget_policy fue defendible; tail-aware no mejoró sin aumentar breach de cola; el estado final permanece research-grade, not promoted.

Observed smoke pattern:

Return_p > Return_xi, Vol_p <= Vol_xi, DD_p <= DD_xi,
but UC_p <= 1 or CVaR_p > CVaR_xi in some candidates.

La conclusión correcta es no declarar producción hasta pasar full research: windows>=12, universe>=90, bootstrap>=300/500, WRC/SPA/PBO estrictos y final holdout congelado.

40. Teoremas finales de gobernanza cuantitativa

Teorema 40.1 (No hay dominancia gratuita). Bajo restricciones long-only equity sin leverage, shorts, derivados ni cash/bond sleeve dinámico, no puede garantizarse para todo periodo $R_p > \max \Omega$ y $D_p < \min \Omega$.

Demostración. Si Ω contiene benchmarks con perfiles incompatibles, por ejemplo QQQ growth y USMV low-vol, superar simultáneamente el upside del primero y downside del segundo exige convexidad que no está disponible en un simplex long-only estático salvo coincidencias de muestra. La garantía universal violaría la heterogeneidad de payoff del conjunto. QED.

Teorema 40.2 (Dominancia promocionable). Una estrategia puede considerarse promocionable sólo si su superioridad OOS sobre x_i permanece después de controlar multiple testing y downside.

Demostración. El active return positivo prueba diferencia muestral, no skill. WRC/SPA corrigen data snooping; PBO evalúa inestabilidad de selección; DD/CVaR/downside protegen suitability. La conjunción de gates es condición operacional de promoción. QED.

Teorema 40.3 (Valor agregado de Kaizen). El valor del framework reside en adaptar exposición a uncertainty state, no en maximizar una métrica aislada.

Demostración. RMT, Kalman/state-space, GARCH/Volterra, Fisher/CRLB y entropía reducen dimensiones distintas de incertidumbre. Si todas se usan como restricciones/gobernadores y no como grados libres sin control, reducen probabilidad de asignar capital a señales espurias. QED.

A. Pseudocódigo del pipeline

Input config, load cached market data, build PIT fundamentals, infer regime, choose xi, rank sector-normalized candidates, estimate uncertainty state, optimize sleeves, run nested walk-forward, compute WRC/SPA/PBO, persist dashboard_payload.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

B. Contrato dashboard_payload

status: suitability, promotion, data_freshness; allocation: recommended_portfolio, weights; charts: price_paths, drawdowns, forecast_cone, conditional_vol, rate_curves; tables: fundamentals, risk, validation, rejections.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

C. Tests mínimos

future contamination must fail; RMT covariance PSD; Volterra kernel causal; Kalman state no future data; Optuna/PSO no test access; XCDDR degrades with CRLB, turnover or entropy collapse.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

D. Checklist de producción

Rotate keys; apply RLS; keep service_role server-side; daily refresh before 09:00 CT; Streamlit render-first; user-safe explanations; no recommendation if gates fail.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

E. Glosario

xi: optimal mandate benchmark; Omega: benchmark stress set; UC: upside capture; DC: downside capture; PIT: point-in-time; WRC: White Reality Check; SPA: Superior Predictive Ability; PBO: Probability of Backtest Overfitting.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

F. Limitaciones costo-cero

No survivorship-free institutional universe, no historical options chain, no true PIT Yahoo fundamentals, no bid/ask historical microstructure, no tax-aware broker execution.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

G. Roadmap research

TailAwareGrowthSleeve, ConvexOpportunityUniverseBuilder, Student-t EGARCH, OOS QLIKE, benchmark-cluster validation, perturbation red-team, Next.js PWA render-only.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

H. Roadmap UX

Investor Mode, Expert Mode, dashboard-first, mobile bottom nav, evidence panel, assistant RAG, daily freshness status, clear blocked/research/promoted states.

Invariant: frontend renders artifacts; quant engine computes; database audits.

Este apéndice forma parte del contrato operativo del framework y debe mantenerse alineado con cambios de versión de modelo, app y schema.

Cierre formal

Quant Portfolio-Kaizen debe entenderse como una plataforma de decisión bajo incertidumbre. Su rigor no depende de una métrica aislada, sino de la coherencia entre filtración, disponibilidad de datos, benchmark governance, reducción de incertidumbre, optimización robusta, validación adversarial y comunicación responsable al usuario final.

Final contract:

If Suitability != Approved -> Blocked.

If PromotionGate != Passed -> Research-only.

If DataFreshness == Stale -> Require refresh.

Only then may the app display a recommended allocation.